



大连海事大学
DALIAN MARITIME UNIVERSITY

本科毕业论文

题目： 基于深度学习的无人机航拍图像小目标检测方法

Small Object Detection Method for UAV Aerial

Title: Images Based on Deep Learning

姓 名： 江锦哲

学 号： 2220223297

学 院： 信息科学技术学院

专业年级班级： 计算机科学与技术 2022-2

指 导 教 师： 刘洪波 教授

第 二 导 师：

完 成 日 期： 2026 年 5 月

毕业论文原创性声明

本人郑重声明：所呈交的毕业论文《基于深度学习的无人机航拍图像小目标检测方法》，是本人在导师的指导下，独立进行研究工作所取得的成果。除论文中已经注明引用的内容外，对论文的研究做出重要贡献的个人和集体，均已在文中以明确方式标明。本论文中不包含任何未加明确注明的其他个人或集体已经公开发表或未公开发表的成果。本声明的法律责任由本人承担。

学生签名：

日 期： 年 月 日

毕业论文版权使用授权书

本人完全了解并同意遵守学校有关毕业论文知识产权的规定，在校学习期间论文工作的知识产权属于大连海事大学，学校有权保留送交毕业论文的副本，向国家有关部门或机构送交论文的复印件和电子版，允许该论文被查阅，可以将本毕业论文的全部或部分内容编入有关数据库进行检索，可以采用影印、缩印、或扫描等复制手段保存和汇编本毕业论文。

涉密的毕业论文在解密后使用本声明。

学生签名：

日 期： 年 月 日

指导教师签名：

日 期： 年 月 日

第二导师签名：

日 期： 年 月 日

摘 要

近年来，无人机已逐步进入交通巡查、安防监测、灾害评估、农业巡检和城市管理等多类场景，无人机图像数据的自动分析需求也随之增加。与常规自然场景图像相比，无人机航拍图像具有俯视视角、高空成像和覆盖范围大的特点，图像中的目标往往只占据较少像素、特征较少因而难以被检测到，同时还伴随目标密集、尺度变化明显和背景复杂等情况。这些因素使现有检测模型在无人机场景下更容易出现漏检、误检和定位不准确等问题，尤其在小目标检测时更为突出。

本文基于 YOLOv8 (You Only Look Once version 8) 进行研究，从浅层细节保留、多尺度特征提取、关键区域增强以及模型复杂度控制四个方面对网络结构进行改进。首先，在原有检测框架中引入 P2 检测层，以增强模型对浅层高分辨率特征的利用能力，使小目标细节信息更多参与预测，从而提高小目标检测和定位能力。在网络中加入多尺度卷积模块 MKIR (Multi-Kernel Inverted Residual)，以提升主干网络的多尺度特征提取能力，改善小目标特征表达不足的问题，并提升模型对尺度变化目标的适应能力；然后，引入三重注意力机制，对关键区域特征进行增强，并抑制复杂背景中的无关干扰，进一步提高模型检测性能；最后，基于 PConv (Partial Convolution) 构建 C2f_PConv 模块，并将其用于替换部分 C2f 模块，在保持模型检测性能的同时，对参数量和计算量进行控制。

实验部分以 VisDrone 无人机数据集为对象，对改进后的模型进行了训练和测试。结果表明，在小目标检测任务中，相较于基线 YOLOv8m，改进模型在 mAP (mean Average Precision) @0.5 指标上提升了 5.2%，在 mAP@0.5:0.95 指标上提升了 3.1%。这说明这种方法可以改善无人机航拍图像中的小目标检测效果。并在交通巡查、安防监测、灾害评估、农业植保等无人机图像分析任务中具有一定应用价值。

关键词：无人机；小目标检测；YOLOv8；多尺度卷积；注意力机制

ABSTRACT

In recent years, unmanned aerial vehicles (UAVs) have been used in traffic inspection, security monitoring, disaster assessment, agricultural inspection, and urban management. With the growth of these applications, the demand for automatic analysis of UAV images has also increased. Compared with ordinary natural-scene images, UAV aerial images are usually captured from a top-down view and cover a larger area. Many targets in these images are small and contain limited visual information. At the same time, dense distribution, scale variation, and complex backgrounds make detection more difficult. Because of this, missed detections, false detections, and inaccurate localization often appear in UAV small-object detection tasks.

This paper takes YOLOv8 as the baseline model and improves it from four aspects, including shallow-detail preservation, multi-scale feature extraction, key-region enhancement, and model-complexity control. First, a P2 detection layer is added to make better use of shallow high-resolution features. In this way, more details of small targets can be used for prediction, which helps improve small-target detection and localization. Second, an MKIR(Multi-Kernel Inverted Residual) module is introduced into the backbone to strengthen multi-scale feature extraction and improve the model's ability to deal with targets of different sizes. Third, a Triplet Attention module is used to enhance target-related features and reduce background interference. Finally, a C2f_PConv module is built based on PConv(Partial Convolution) and used to replace part of the original C2f modules. This helps control the number of parameters and computational cost while maintaining the detection performance of the model.

Experiments are carried out on the VisDrone UAV dataset. The improved model is trained and tested on this dataset. Compared with the baseline YOLOv8m, the proposed method improves mAP(mean Average Precision)@0.5 by 5.2% and mAP@0.5:0.95 by 3.1% in small-object detection tasks. This shows that the proposed method can improve small-object detection in UAV aerial images and has certain application value in UAV image analysis tasks such as traffic inspection, security monitoring, disaster assessment, and agricultural plant protection.

Keywords: UAV; small object detection; YOLOv8; multi-scale convolution; attention mechanism

目 录

第 1 章 绪论	1
1.1 背景及意义	1
1.2 国内外研究现状	2
1.2.1 传统目标检测方法研究现状	2
1.2.2 基于深度学习的目标检测方法研究现状	3
1.2.3 无人机航拍图像小目标检测研究现状	4
1.3 本文的主要研究内容	6
1.4 论文组织结构	6
第 2 章 相关技术基础	8
2.1 卷积神经网络基础	8
2.1.1 卷积层	8
2.1.2 池化层	9
2.1.3 激活函数	9
2.1.4 全连接层	10
2.2 目标检测算法理论基础	11
2.2.1 双阶段目标检测算法	11
2.2.2 单阶段目标检测算法	12
2.2.3 YOLOv8 目标检测算法	12
2.3 本章小结	18
第 3 章 面向无人机航拍图像的小目标检测模型改进	19
3.1 新增小目标检测层 P2	20
3.2 多尺度卷积 MKIR	20
3.3 三重注意力模块	23
3.4 基于部分卷积的 C2f_PConv 模块	24
3.5 本章小结	26
第 4 章 实验设计与结果分析	27
4.1 实验配置	27
4.2 数据集与评价指标	28
4.2.1 数据集介绍	28
4.2.2 目标检测评价指标介绍	30
4.3 对比实验	31
4.4 消融实验	32
4.5 可视化分析	34

4.5.1 训练过程可视化分析	34
4.5.2 各类别检测性能可视化分析	35
4.5.3 检测结果可视化分析	37
4.5.4 检测结果热力图分析	37
4.6 本章小结	38
结论与展望	39
参考文献	41
致谢	44

基于深度学习的无人机航拍图像小目标检测方法

第 1 章 绪论

1.1 背景及意义

近年来,无人机技术在机动性、成像精度以及适用范围方面取得较大进展,已逐步应用到交通巡查、灾害搜救、农业植保和设施巡检等场景中^[1-3],如图 1.1 所示。与固定摄像头或人工地面巡查方式相比,无人机能够在更短时间内到达目标区域,并从高空获得更大范围的现场信息。这种成像方式一方面提高了信息获取效率,另一方面也使无人机成为复杂场景感知的重要载体。随着应用场景不断扩展,如何利用无人机采集的图像完成有效目标识别,已成为当前智能感知研究中的一个实际问题^[4]。



(a) 交通巡查



(b) 灾害救援



(c) 农业植保



(d) 设施巡检

图 1.1 无人机应用领域

随着深度学习技术的不断发展,计算机视觉方法在无人机领域中的应用逐步由图像获取扩展到图像分析与智能感知。依托深度学习较强的特征学习能力,无人机采集的航拍图像不仅可以用于场景记录,还可以进一步完成目标检测、目标跟踪和场景理解等任务。在上述视觉任务中,目标检测处于较为靠前的位置。模型需要先从无人机航拍图像中找出目标所在区域,并给出对应类别,后续的目标跟踪、信

息统计和场景分析通常都建立在这一结果之上。如果检测阶段出现漏检、误检或定位偏差,后续处理效果也会受到影响。基于这一点,围绕无人机航拍图像开展目标检测研究具有较强的现实需求^[5],也为后文工作提供了直接背景。

相较于传统的地面影像,无人机在空中航拍的图像在拍摄方式和场景表现上具有较强的特殊性。受拍摄高度、俯视角度和成像范围等因素影响,图像中的目标通常尺度较小,在整幅图像中所占像素较少,因而不利于对目标进行识别。在无人机航拍场景中,目标往往分布较为密集,尺度差异比较明显,背景成分复杂,并且常伴随局部遮挡的情况。这些因素会影响目标的识别和定位,使检测过程中容易发生漏检、误检和定位偏差。特别是针对小目标,其自身所拥有的可用判别信息本就偏少,而神经网络能够获取的特征也比较有限,并且在经历多次下采样处理及受到复杂背景干扰的情况下,这些特征容易受到削弱,所以无人机航拍图像中进行小目标检测一直属于目标检测研究中的难点问题。

针对无人机航拍影像中的小目标识别问题,仍有待进一步深入探索。在交通巡查场景中,提高小目标检测精度能够更加准确地识别车辆、行人以及道路中的异常目标,并为交通状态分析和安全监管工作提供支持。在灾害评估和应急搜救过程中,较高的检测准确率有助于及时发现关键目标,进而提高搜寻效率。无人机在农业植保和基础设施巡检等任务中,稳定的小目标检测能力也能够提升其获取场景信息的质量。提高基于深度学习的无人机航拍图像小目标检测水平,有助于改善模型在复杂环境中的检测表现,也更贴合无人机巡检和监测等实际任务的需要。

1.2 国内外研究现状

在计算机视觉领域,目标检测任务旨在识别图像中的特定对象并精确定位其空间位置。传统方法主要依赖人工构建的特征,而随着深度学习的兴起,基于神经网络的端到端特征提取方法显著提升了检测性能^[6]。现有主流目标检测方法在常规自然场景中已经获得较好的检测效果,但在无人机影像等特定场景上,仍然面临比较大的挑战。无人机一般在高空进行俯视拍摄,图像中车辆和行人等目标的尺寸比较小,并且受到背景复杂、目标密集、遮挡和尺度变化等因素的影响。这意味着针对常规场景进行设计的检测方法在无人机航拍任务里难以直接达到理想效果,漏检、误检、定位偏差等情况仍比较常见。本节先从传统目标检测方法讲起,再介绍基于深度学习的目标检测方法,最后落脚到无人机航拍图像小目标检测的相关研究。

1.2.1 传统目标检测方法研究现状

早期目标检测方法并不依赖深度网络,而是以人工设计特征为主完成目标识别。一般先在图像中按照不同位置和尺度生成候选区域,再从这些区域中提取具有代表性的手工特征,如尺度不变特征变换(Scale-Invariant Feature Transform, SIFT)

[7]和方向梯度直方图（Histogram of Oriented Gradients, HOG）[8]，后续交由支持向量机等分类器进行判别，以确定其是否包含目标。这类方法整体思路比较清晰，实现起来也相对直接。在目标边界较明显、背景较简单的情况下，往往能够取得一定效果，因此在目标检测研究早期被广泛采用。

随着研究的深入，研究者逐渐发现，仅依靠边缘、纹理等局部手工特征，难以稳定应对形变、遮挡和尺度变化较大的目标。为改善这一问题，Felzenszwalb 等人提出了可变形部件模型（Deformable Part Model, DPM）[9]。该方法将目标看作由多个部件组成，并进一步考虑部件之间的空间关系，从而使模型对目标结构信息的表达更加充分。与更早的手工特征方法相比，DPM 在复杂目标检测任务中的表现更好，也在一段时间内成为传统目标检测方法中的代表性工作。

不过，从整体上看，传统目标检测方法仍然存在较多不足。这类方法对人工特征设计依赖较强，不同场景下往往需要针对特征和参数进行调整，模型的适应能力有限。同时，这类方法往往需要在不同位置和尺度上反复搜索候选区域，计算量较大，处理速度也会受到限制。当图像中出现复杂背景、目标遮挡或尺度变化明显等情况时，手工特征往往难以充分描述目标的判别信息，检测精度和泛化能力都会受到影响。也正因如此，目标检测方法后来逐步转向依靠数据自动学习特征的深度学习路线。

1.2.2 基于深度学习的目标检测方法研究现状

深度学习被应用到目标检测任务后，检测方法的重点由人工特征设计转向网络自动特征学习。卷积神经网络可以直接从图像样本中提取由浅到深的特征表示，并且把边缘和纹理等低层信息逐步组合成具有语义性的目标特征。对比传统方法，这类方法降低了人工设计特征带来的限制，在复杂场景、目标形变和背景变化等情况下的适应性更好。所以，基于深度学习的目标检测方案，到了现阶段是逐步占据了更主要的位置。

从执行流程上看，深度学习目标检测方法主要分为两类：先提取候选区域再分类回归的两阶段方式，以及直接在特征图上输出类别和边界框的单阶段方式。前者的代表性方法有 R-CNN（Region-based Convolutional Neural Network）[10]、Fast R-CNN[11]和 Faster R-CNN[12]。较早提升检测效果的是 R-CNN，它的做法是用卷积神经网络去提取每个候选区域的特征。后续的 Fast R-CNN 则靠共享卷积特征这一技巧，省去了不少重复计算。再到 Faster R-CNN 出现，它引入了一个区域建议网络，让候选框的生成能和后续检测环节更好地对接起来。两阶段方法一般拥有较好的检测精度，不过该方法仍然包括候选区域处理步骤，模型结构和推理流程比较复杂。

与双阶段检测不同，单阶段检测方法没有单独进行候选区域生成，在特征图上直接对类别进行预测并对边界框进行回归。SSD（Single Shot MultiBox Detector）[13]使用多尺度特征进行预测，其对不同尺寸的目标适应性较好。RetinaNet[14]为了

解决前景和背景样本分布不均的问题，加入了 Focal Loss 函数，减少了大量易分类背景样本对训练的影响。YOLO（You Only Look Once）^[15]系列对检测流程进行了简化处理，可以只进行一次前向传播就同时输出目标位置和类别结果，因此在检测速度和部署效率上表现良好。

除了卷积神经网络模式之外，Transformer 也被逐步地引入到目标检测任务中。DETR（Detection Transformer）^[16]把检测过程看作集合预测问题，减少了对候选框设计和复杂后处理的依赖。Deformable DETR^[17]利用可变形注意力解决了原始 DETR 收敛速度较慢、对小目标特征利用不充分的问题。DINO（DETR with Improved DeNoising Anchor Boxes）^[18]和 RT-DETR（Real-Time Detection Transformer）^[19]等方法则进一步从训练策略、多尺度特征表达和实时性能等方面进行了优化。

总体来看，深度学习目标检测方法已经形成了较为丰富的技术路线，并在常规场景中取得了较好效果。其中，单阶段检测方法结构相对紧凑，检测速度较快，在实时检测和工程应用中具有较高的使用价值。YOLO 系列作为单阶段检测方法的代表，兼顾了检测精度和推理效率，便于后续针对具体任务进行结构改进。

1.2.3 无人机航拍图像小目标检测研究现状

无人机航拍图像中的目标检测与常规场景相比具有更强的特殊性。受成像高度、俯视视角和视野范围等因素影响，图像中的目标往往占比不大，经过网络逐级下采样后，其细节信息更容易被削弱。与此同时，无人机航拍场景中经常出现目标分布聚集、局部存在遮挡、尺度差异较大、背景环境复杂等情况，这些因素都会增加小目标检测的难度。针对上述问题，国内外学者在不同检测模式上进行了大量研究，并持续尝试利用结构改进来提高模型在无人机航拍场景中的检测能力。

早期的相关研究主要从浅层特征增强和高分辨率信息利用着手。Sommer 等人^[20]针对航空影像中小目标检测问题，对 Faster R-CNN 进行了改进，通过反卷积上采样处理深层特征，并且和浅层高分辨率特征相结合，让特征图保留了较多细节信息，以提升模型性能。Liu 等人^[5]后来提出了 UAV-YOLO，该模型在 YOLOv3 模式上对残差结构和特征提取流程进行了调整，通过在前端网络中增加卷积操作，增强了空间信息表征并扩大了感受范围，使模型对无人机图像中小目标检测的性能得到提高。Song 等人^[21]没有选择 YOLO 路线，而是提出使用 SSD 的 RSAD 算法。该算法运用了更好的主干特征提取结构、自注意力机制和改进的特征融合方式，使模型对小目标区域的特征描述更加完整，使其在无人机场景中的检测更加稳定。

随着 YOLO 系列模型的不断发展，研究重点逐渐由单纯增强浅层特征转向多尺度特征融合、检测头设计和上下文信息建模。Zhu 等人^[22]提出 TPH-YOLOv5，通过在 YOLOv5 网络中增加额外预测头，并引入 Transformer Prediction Head 和 CBAM（Convolutional Block Attention Module）模块，以加强模型对密集遮挡目标和尺度变化目标的上下文建模能力，从而提升其在无人机场景中的小目标定位与

识别表现。Zhang 等人^[23]提出 Drone-YOLO，通过对特征融合结构进行重构，并结合无人机图像特点设计不同检测模型，提高了网络对密集小目标、低照度目标以及复杂背景目标的适应能力。可以看出，这一阶段的研究已经不再局限于单一级特征增强，而是开始更加关注不同尺度特征之间的信息交互，以及模型在复杂场景中的整体适应能力。

近年来，随着 YOLOv5、YOLOv8 和 YOLOv11 等模型在目标检测任务中的广泛应用，越来越多的研究开始围绕骨干网络、颈部融合结构、上采样方式和检测头进行针对性改进。何宇豪等人^[24]针对无人机图像中小目标易漏检、背景干扰较强的问题，提出了改进的 YOLOv5 检测方法。该方法通过增加小目标检测头，并在特征融合阶段引入 BiFPN（Bidirectional Feature Pyramid Network）与 CBAM 等结构，增强了网络对多尺度目标特征的整合能力和关键区域特征表达能力，这样一来，无人机航拍场景中的小目标检测表现得到提升。何植仟等人^[25]提出 UAVAI-YOLO 模型，在检测框架中引入可变形卷积、P2 检测层、双向特征融合结构以及改进的定位损失函数，从而提高模型对小尺度目标的空间表征能力和边界框回归效果。Ni 等人^[26]提出了一种面向无人机场景的改进 YOLOv8s 小目标检测模型，在网络中设计并行多尺度特征提取模块 PMSE，利用并行空洞卷积和可变形卷积构建不同感受野下的特征响应，从而增强浅层细节信息表达能力并提高小目标检测精度。Qi 等人^[27]提出 MSFE-YOLO，在 YOLOv8 基础上构建多尺度特征增强结构，并在颈部网络中引入注意力机制与特征融合模块，通过加强多尺度特征之间的级联交互，提升了模型在复杂场景下对小目标的检测效果。Chen 等人^[28]提出 PCPE-YOLO，在 YOLOv8 中设计特征增强模块，并结合注意力机制、小目标检测层和改进上采样结构，在尽量保持网络整体稳定性的基础上，提高了复杂背景条件下的小目标检测效果。

除卷积检测框架之外，基于 Transformer 的无人机目标检测研究也逐渐增多。Wei 等人^[29]提出了 DV-DETR，该模型在 RT-DETR 上替换骨干网络，加入重校准注意单元和可变形注意机制，并且对边界框损失函数进行调整，提高模型在高密度无人机场景中的目标检测能力。该结果表明，无人机航拍图像小目标检测研究不只局限于单一模型路线，而是在各种检测模式中都表现出调整的趋势。

无人机航拍图像小目标检测的相关研究，已经由早期的浅层特征增强，发展到了多尺度特征融合、注意力机制引入及颈部结构优化等这样一个阶段。相关研究在提升小目标感知能力和改善复杂背景下的特征表达方面取得了较多进展，但在目标尺寸较小、尺度变化明显以及存在局部遮挡时，现有方法仍难以同时兼顾细节保留、特征增强和复杂度控制。在这类任务中，结构相对紧凑、推理速度较快的单阶段检测器更便于进行针对性改进。YOLO 系列作为其中的代表，兼顾了检测精度和效率，且在骨干网络、颈部融合结构和检测头设计上具有较强的可扩展性。基于上

述情况，本文选用 YOLOv8 作为基线模型。它在精度和速度之间较为均衡，结构也比较成熟，便于改动，因此更适合作为本文的基础模型。

1.3 本文的主要研究内容

无人机航拍场景下，目标尺寸偏小，同时存在目标密集、背景复杂、尺度变化明显等现象，这使得现有检测模型容易出现特征提取不足、漏检偏多和定位不稳。基于这些实际情况，本文选取 YOLOv8m 作为基础模型，从添加高分辨率检测层、多尺度特征提取、注意力机制和模型复杂度控制四个方面进行改进，提出一种更适合无人机航拍场景下的检测方法。本文的主要工作如下。

(1) 小目标在原始图像中本身占用的像素就不多，经过多次下采样后，边缘、纹理和位置信息会进一步减弱，容易影响后续检测。针对这一情况，本文在原有检测结构中加入 P2 检测层，将检测层由 P3、P4、P5 扩展为 P2、P3、P4、P5 四个尺度。由于 P2 层对应的特征图分辨率更高，浅层细节特征能够更早参与预测，因此小目标的细节信息可以保留得更充分，这对极小目标和密集小目标的检测具有积极作用。

(2) 无人机拍摄时的高度和角度并非固定，因此同一场景中目标的尺寸差异较大；加之小目标像素占比较低、特征信息有限，若仅采用单一尺度的卷积进行特征提取，网络的感受野便会受限，难以同时捕捉局部细节与周围上下文信息。针对这一问题，本文在主干网络中引入 MKIR 多尺度卷积模块，该模块通过并行多个不同感受野的卷积分支提取特征，从而提升主干网络的多尺度特征提取能力，缓解小目标特征表达不足的问题，并增强模型对尺度变化的适应能力。

(3) 无人机航拍图像中背景信息较多，局部遮挡也比较常见，这会使本来就不显眼的小目标更难被准确识别。考虑到这一点，本文在特征融合阶段加入三重注意力机制。该模块会对融合后的特征进行有选择的增强，让网络更多关注目标所在区域及其关键信息，同时减弱无关背景带来的干扰，从而提升复杂场景下对小目标的识别与定位能力。

(4) 前面几项改进提升了特征表达能力，但同时也会带来额外的参数量和计算量。为了让模型复杂度保持在较为合理的范围内，本文进一步引入基于部分卷积的 C2f_PConv 结构，对主干网络深层和颈部末端的部分 C2f 模块进行替换。该结构只对部分通道执行空间卷积，其余通道保留原有特征传递路径，在尽量保持检测性能的前提下，对模型规模和计算开销进行控制。

本文针对无人机航拍图像中小目标容易漏检、尺度变化较大以及背景干扰较强的情况，在 YOLOv8m 基础上进行了改进，并通过 VisDrone 数据集完成了验证。

1.4 论文组织结构

全文由五章构成，各章内容之间前后衔接，具体安排如下。

第 1 章主要交代研究背景、问题来源以及国内外相关研究进展，并在此基础上说明本文的研究对象、主要工作和整体写作思路。

第 2 章围绕本文后续改进所依赖的基础内容展开，重点介绍卷积神经网络、目标检测的基本流程以及 YOLOv8 的网络结构，为后面的模型改动作基础说明。

第 3 章给出本文提出的改进方法，分别对 P2 检测层、MKIR 多尺度卷积、三重注意力机制和 C2f_PConv 模块进行说明，交代它们的设计思路、放置位置以及在网络中起到的作用。

第 4 章结合 VisDrone 数据集，对改进前后的模型进行对比实验、消融实验和可视化分析，用实验结果验证各个改进模块的效果。

第 2 章 相关技术基础

2.1 卷积神经网络基础

卷积神经网络（Convolutional Neural Network, CNN）是图像处理任务中常用的一类网络结构，其基本作用是通过卷积运算逐层提取图像特征。与直接采用全连接方式处理图像相比，CNN 能够更好地利用图像的局部空间关系，并在控制参数规模的同时逐步形成从浅层纹理到深层语义的特征表示。结合本文后续模型分析，下面对卷积层、池化层和激活函数等基本结构作简要说明。

2.1.1 卷积层

卷积层作为卷积神经网络中最核心的组成部分之一，主要负责从图像中逐步提取局部特征。它通过卷积核在特征图上不断移动，把边缘、纹理和轮廓等信息一层层提取出来，再组合成更高层次的特征表示。由于卷积核中的参数可在训练过程中不断更新，卷积层能够对边缘、纹理等局部模式形成有效响应。卷积运算如式（2.1）所示，其中， $g(i, j)$ 表示输出特征图在位置 (i, j) 处的值， $I(i + m, j + n)$ 表示输入特征图对应邻域中的元素， $K(m, n)$ 表示卷积核权重， b 表示偏置项。

$$g(i, j) = \sum_m \sum_n I(i + m, j + n) K(m, n) + b \quad (2.1)$$

如图 2.1 所示，卷积可以理解为在输入特征图上进行局部范围内的信息提取。以 (5×5) 输入特征矩阵和 (3×3) 卷积核为例，步长取 1 时，卷积核每次移动都会获得一个新输出值，连续进行计算后可以形成完整输出特征图。这样的处理方式既能保留原有的空间联系，也能逐步提取出更有用的特征表示。




图 2.1 卷积运算示意图

2.1.2 池化层

在卷积神经网络中，池化层主要用于对特征图进行下采样，以减小特征图尺寸并降低后续计算量。与卷积层通过学习参数完成特征变换不同，池化层通常直接对局部区域内的特征进行统计，从而保留主要信息并简化特征表示。

池化层的作用主要是对局部特征进行压缩和筛选，在减小特征图尺寸的同时保留更有代表性的响应。最大池化更偏向于突出局部区域中的显著信息，因此有利于保留目标中较强的特征；平均池化则通过对区域内响应取均值，使输出结果更加平缓，反映的是局部区域的整体变化情况。如图 2.2 所示，池化可以理解为一个局部窗口内提取一个代表值，从而实现特征压缩和信息整理。

需要指出的是，池化在减少计算量的同时，也会带来一定的信息压缩。对于一般分类任务，这种影响通常较小；但在目标检测，尤其是小目标检测中，若下采样过多，目标边缘、纹理和位置信息可能被削弱。因此，在检测网络设计中，需要兼顾特征图分辨率与高层语义表达之间的关系。




图 2.2 池化运算示意图

2.1.3 激活函数

卷积和全连接运算本身都属于线性变换，如果网络各层只进行线性叠加，即使层数增加，模型能够表示的关系仍然有限。为了应对这种限制，激活函数为卷积神经网络注入了非线性变换能力，这是网络得以突破线性约束、进而学习复杂特征的关键。

常见的激活函数包括 Sigmoid^[30]、ReLU^[31]、Leaky ReLU^[32]和 SiLU^[33]等。不同激活函数对输入的响应方式不同，也会影响特征传递和训练过程。YOLOv8 采用的是 SiLU 激活函数，如式 (2.2) 一式 (2.5) 所示。相较于较为简单的分段激活方式，SiLU 在变化上更加平滑，在网络优化过程中通常表现更稳定，因此更适合用于本文所研究的检测模型。如图 2.3 为几种常用的激活函数曲线图。

$$\text{Sigmoid}(x) = \frac{1}{1 + e^{-x}} \quad (2.2)$$

$$\text{ReLU}(x) = \max(0, x) \quad (2.3)$$

$$\text{SiLU}(x) = \frac{x}{1 + e^{-x}} \quad (2.4)$$

$$\text{LeakyReLU}(x) = \begin{cases} x, & x > 0 \\ \alpha x, & x \leq 0 \end{cases} \quad (2.5)$$




图 2.3 经典激活函数曲线图

2.1.4 全连接层

全连接层会把前面提取到的特征汇总起来，再统一映射到最终的输出空间。它的结构如图 2.4。与卷积层相比，全连接层能够更直接地整合全局信息，但它带来的参数量通常也更大。当输入特征维度较高时，模型规模会明显增加，训练和存储开销也会随之上升。因此，随着卷积神经网络的发展，许多视觉模型开始减少对全连接层的依赖，转而采用全局池化或卷积预测等方式完成输出映射。

在目标检测任务中，全连接层的使用方式与早期分类网络并不完全相同。一些两阶段检测模型仍会在候选区域特征处理后使用全连接层完成分类和回归，而许

多单阶段检测模型则更多采用卷积方式直接输出预测结果。总体来看，全连接层在视觉模型中仍具有一定作用，但在目标检测网络中的使用已经明显减少。




图 2.4 全连接层示意图

2.2 目标检测算法理论基础

目标检测的任务不仅要判断图像中是否存在目标，还要给出目标所在的位置，因此它同时涉及分类与定位两个方面。依据检测过程的组织方式不同，深度学习目标检测方法一般形成了双阶段和单阶段两类技术路线。二者在候选区域生成方式、特征利用思路以及最终预测流程上存在明显区别。由于本文后续研究是在 YOLOv8 基础上展开的，而 YOLOv8 属于单阶段检测框架，因此本节先对双阶段和单阶段目标检测的基本思路进行简要说明，再结合 YOLOv8 模型结构进行分析，为后续改进模型设计作铺垫。

2.2.1 双阶段目标检测算法

将检测过程划分为两个步骤是双阶段目标检测方法的核心：首先生成可能包含目标的候选区域，然后在此基础上完成类别判别和位置回归，其基本流程如图 2.5 所示。

与直接输出检测结果的方式相比，双阶段方法先对候选区域进行筛选，再开展更细致的分类与定位，因此通常具有较好的检测精度。R-CNN、Fast R-CNN 和 Faster R-CNN 是其中几种经典的方法，其发展过程也体现了双阶段检测从独立候选区域提取逐步走向特征共享和端到端优化的演变趋势。总体来看，双阶段目标检测算法在目标识别和定位方面表现较好，但由于流程相对复杂，计算开销通常较大，在实时性要求较高的场景中难以应用。




图 2.5 双阶段目标检测算法结构示意图

2.2.2 单阶段目标检测算法

单阶段目标检测方法不再将候选区域生成作为单独步骤，而是直接在特征图上完成目标类别判别和边界框预测，其流程如图 2.6 所示。相比双阶段方法，这类方法将大部分检测任务集中在一次前向过程中完成，因而整体结构更紧凑，推理速度也更快。

SSD 和 YOLO 作为单阶段方法的代表，会直接把预测过程放在几种不同分辨率的特征图上来完成，以此去覆盖尺度差异较大的目标。由于省去了候选区域筛选这一中间过程，单阶段方法在检测效率和部署便利性方面更具优势，因此更适合实时性要求较高的应用场景。由于网络结构、特征提取方式以及检测头设计等方面的持续优化，单阶段算法在维持其速度优势的基础上，检测精度也得到了持续提升，已经成为当前目标检测研究中的重要技术路线之一。




图 2.6 单阶段目标检测算法结构示意图

2.2.3 YOLOv8 目标检测算法

YOLOv8 被用作本文改进模型的基础框架，其前向计算过程会先后经过输入预处理、骨干特征提取、颈部多尺度融合以及检测头这四个阶段。图像输入后，先进行尺寸调整和数据增强等处理，再由骨干网络提取多层特征，经颈部网络进行多尺度融合，最后通过检测头输出目标类别和边界框信息。因本文改进工作均以 YOLOv8 模型为基础，所以本节会对其中的主要结构和重要模块进行了说明，从而为后续的方法设计打下基础。

YOLOv8 在检测精度和推理效率方面达到较好平衡，可以适应大部分通用目标检测任务。不过，在无人机进行航拍小目标检测的场景里，由于目标尺寸较小，尺度变化幅度较大，且背景环境复杂，因此原始结构在利用浅层细节、表达多尺度特征、抑制背景干扰上仍存在改进空间。本节在介绍 YOLOv8 结构的同时，还会结合任务特点对相关改进需求进行简要分析，并在第三章中进一步展开具体的改进方法。




图 2.7 YOLOv8 网络结构图

(1) 输入数据预处理部分

输入预处理的作用是把原始图像整理成网络可以直接接收的形式，以保证后续的训练和预测过程可以顺利进行。YOLOv8 模型把输入图像进行尺寸缩放和归一化处理后，再通过填充方式调整到设定尺寸，便于后续的特征提取和目标预测。训练过程中会运用 Mosaic、随机缩放、随机翻转、平移、颜色扰动等数据增强方

法，使样本在尺度、位置和光照上展现更多变化，从而使模型对复杂场景的适应能力得到提高。

（2）骨干特征提取网络

骨干网络位于 YOLOv8 的前端，主要承担图像特征提取任务，并向后续颈部网络和检测头提供不同层级的特征图。从整体过程看，YOLOv8 骨干网络采用逐级下采样的方式对输入图像进行处理：每一阶段先通过 CBS（Convolution-Batch Normalization-SiLU）模块下采样并调整通道数，使特征图尺寸逐步减小、通道数逐步增加；当前尺度下的特征，接着会经过 C2f 模块的再提取与融合处理；行进到骨干网络末尾时，SPPF 模块被用于扩展感受野，以便引入来自更大空间范围内的上下文信息。经过上述处理后，网络能够形成由浅层到深层的多级特征表示。CBS、C2f 和 SPPF（Spatial Pyramid Pooling-Fast）这三个组件，共同构成了 YOLOv8 骨干网络的核心。接下来的内容会分别说明它们各自的设计结构以及在网络里承担的角色。

在骨干网络的具体实现中，前端主要由 CBS 单元承担基础特征变换与下采样任务。如图 2.8 所示，在 CBS 单元中，输入数据依次经过卷积层、批量归一化层（BN）和 SiLU 激活函数。该单元主要负责特征提取、通道调整以及下采样等操作。其中，卷积层负责提取局部模式并进行通道变换，BN 用于减小训练过程中不同批次特征分布的波动，SiLU 则为网络引入非线性表达能力。由于结构相对简洁，CBS 在骨干网络前部主要承担下采样和基础特征提取作用，同时，这种卷积组合形式也构成了 Bottleneck 单元中的基本运算结构。



图 2.8 CBS 单元组成结构图

在 YOLOv8 中，C2f 模块承担着特征提取与特征增强的任务，既出现在骨干网络中，也用于颈部网络的特征处理。在完成基础下采样后，YOLOv8 进一步通过 C2f 模块对当前尺度下的特征进行提取与融合，如图 2.9 所示，C2f 模块先对输入特征进行通道变换，并划分为两条分支，这两路特征都会保留参与后续融合；其中一路还会继续经过多个 Bottleneck 单元逐步提取特征，最终将初始分支与各阶段输出一同拼接融合，得到模块输出。与仅保留最终结果的串行提取方式相比，C2f 在特征传递过程中保留并融合了更多中间信息，因此能够在控制复杂度的同时增强特征表达能力。




图 2.9 C2f 模块结构图

其中，Bottleneck 是 C2f 内部进行特征提取的基本单元，其结构如图 2.10 所示。输入特征经过两个 CBS 模块的特征提取后，再通过可选的残差连接与原始输入特征图相加输出。这种设计既有助于进一步提取特征，也有利于保持信息传递的稳定性，从而缓解深层网络中的特征退化问题。总体来看，C2f 正是通过对多个 Bottleneck 单元输出的保留与融合，实现了较为充分的特征增强，因此也是 YOLOv8 中重要的特征提取结构，并在骨干网络和颈部网络中均有应用。




图 2.10 Bottleneck 特征提取单元结构图

不过，随着网络层级加深，尤其是在主干网络较深层的 P4、P5 阶段以及颈部后部位置，C2f 模块的通道数和计算开销会明显增加，而部分通道信息存在一定冗余。对于无人机航拍小目标检测任务而言，模型性能提升更多依赖于浅层细节信息、高分辨率特征以及有效的多尺度融合，而深层特征更多起到语义补充的作用，对其继续进行大开销增强所带来的收益相对有限。基于这一点，本文后续在主干网络深层和颈部末端的部分 C2f 模块中引入部分卷积 PConv 思想，在尽量保持原有 C2f 特征提取能力的基础上，对模型的计算负担和参数规模进行适当控制，相关设计将在第三章详细说明。

在骨干网络末端，YOLOv8m 引入 SPPF 模块进一步处理高层特征，其结构如图 2.11 所示。该模块先对输入特征进行卷积调整，随后通过连续池化操作提取不同范围的上下文信息，最后将各分支特征进行拼接融合。SPPF 这种模块结构的设计，可以以极小的计算量和参数量开销来大幅扩大感受野，使得网络可以学习到更大范围的上下文信息并增强高层语义信息的表达能力。




图 2.11 SPPF 模块结构图

YOLOv8 的骨干网络能够完成由浅到深的层次化特征提取，并为后续特征融合与目标预测提供基础。但在无人机航拍小目标检测场景下，目标尺度变化较明显，小目标本身可利用的特征也较有限，原有骨干网络采用单一尺度卷积核，在特征提取过程中仍难以同时兼顾局部细节和周围区域信息，因此还有进一步优化的空间。基于此，本文在骨干网络相关位置引入 MKIR 多尺度卷积模块，该模块通过不同感受野分支提取特征，这一方面维持了局部细节的完整，另一方面融入了目标周围的区域信息。从而，主干对多尺度特征的捕获能力得到增强。同时减轻了小目标特征表达匮乏的困境。MKIR 的具体结构和改进方式将在第三章中展开说明。

（3）颈部特征融合网络

颈部网络位于骨干网络和检测头之间，主要用于融合不同层级的特征，使浅层保留的细节与位置信息和深层包含的语义信息共同参与后续预测。由于各层特征关注的内容并不相同，单独使用某一层特征往往难以兼顾不同尺度目标的检测需求，因此颈部网络在整个检测流程中起着承接与协调的重要作用。

YOLOv8 的颈部部分融合了 FPN（Feature Pyramid Network）和 PAN（Path Aggregation Network）的思路。其一方面通过上采样把深层特征传递到分辨率更高的层，并与浅层特征进行融合，使高分辨率的特征图保留细节信息的同时，也具备一定语义表达能力；另一方面又通过下采样将融合后的信息重新传回低分辨率层，使浅层中的位置信息和局部细节能够继续补充到深层特征中。经过这样的双向传

递与融合，不同层级之间的信息联系更加充分，最终形成适合多尺度目标检测的特征表示。

在具体结构上，YOLOv8 在颈部网络中同样使用了 C2f 模块，对拼接后的特征进一步处理和整合，使融合结果更加充分。经过颈部网络后，模型输出多个尺度的特征图，并分别送入检测头完成不同尺度目标的预测。可以说，颈部网络承担了多尺度特征融合的核心任务，是 YOLOv8 实现多尺度检测的重要组成部分。

不过，对于无人机航拍图像而言，小目标的特征信息较弱，融合后的特征中也常混入较多背景干扰。基于此，本文在颈部特征融合后的关键节点引入三重注意力机制，以进一步强化目标相关区域并抑制无关背景干扰，具体改进将在第三章中展开。




图 2.12 颈部多尺度特征融合结构图

(4) 检测头输出

检测头处于 YOLOv8 网络的末端，主要负责预测最终检测结果。其输入来自 Neck 输出的多尺度特征图，输出内容主要包括目标类别与边界框信息。在 YOLOv8

中,分类分支和回归分支是分开处理的,这样可以让两类任务各自学习更适合自己的特征,减少相互之间的干扰。

YOLOv8 在进行具体预测时,会运用多尺度检测方法,依靠 P3、P4 和 P5 这三个层级的特征图。这里的 P 代表特征金字塔的输出层级,数值越小,特征图分辨率就越高,所保留的空间细节也就越多。数值越大说明该层进行了较多的下采样操作,特征图分辨率较低,但是语义信息相对较强。以输入尺寸 640×640 为例,这三层特征图的大小分别为 80×80 、 40×40 和 20×20 ,对应的下采样倍率分别为 8、16 和 32。检测头会分别基于这三层特征图进行预测,从而完成不同尺度目标的检测。

对于无人机航拍图像而言,许多目标本身只占据少量像素。随着网络不断下采样,目标的边缘、纹理和位置等信息会逐步减弱。到 P3、P4 和 P5 层进行预测时,极小目标在特征图中对应的有效信息已经较少,部分细节甚至可能被弱化或丢失,因此容易出现漏检或定位不准确的问题。基于这一情况,本文在原有检测头基础上加入 P2 检测层,使更高分辨率的浅层特征能够参与后续预测,相关改进将在第三章展开说明。

从整体检测流程来看,YOLOv8 通过骨干网络、颈部网络和检测头依次完成特征提取、特征融合与结果输出,在通用目标检测任务中具有较均衡的表现。但放到无人机航拍小目标场景中,原始结构在浅层细节保留、多尺度信息利用以及复杂背景下的目标突出方面仍存在进一步优化空间,这也构成了后续模型改进的出发点。

2.3 本章小结

本章围绕本文研究所涉及的基础理论内容展开说明。首先,对卷积神经网络中的卷积层、池化层、激活函数和全连接层等基本组成进行了介绍,并简要分析了它们在特征提取过程中的作用。其次,对目标检测算法的基本发展脉络进行了概述,并重点介绍了 YOLOv8 目标检测算法的整体结构及其 Backbone、Neck 和 Head 等关键组成部分。上述内容为后文改进模型的设计与实验分析提供了理论依据。

第 3 章 面向无人机航拍图像的小目标检测模型改进

在航拍小目标检测任务里，图像中的目标通常较小，分布集中，不同目标之间尺度差异明显，背景干扰信息多，所以现有的方法仍然会经常出现漏检、误检、定位偏差的情况。为了解决上述问题，本文对 YOLOv8m 模型进行了改进，本章将说明该改进模型的整体结构和各个部分的设计。

本文的改进主要包括四个方面，改进后的模型如图 3.1 所示：其一，于检测头中增设 P2 检测层，以强化对小目标细节信息的利用效率；其二，在骨干网络中嵌入 MKIR 模块，借此提升主干对多尺度特征的提取能力；其三，于颈部融合阶段引入 Triplet Attention 模块，用于增强目标区域的特征响应；最后，把部分 C2f 模块替换为 C2f_PConv，以对模型复杂度进行控制。下面将分别展开说明。




图 3.1 改进后的 YOLOv8 网络结构图

3.1 新增小目标检测层 P2

YOLOv8 选取特征金字塔中的 P3、P4、P5 这三层输出，分别送入对应的检测头。给定 640×640 的输入尺寸时，这三层的特征图大小变为 80×80 、 40×40 和 20×20 ，各自代表对原始图像 8 倍、16 倍、32 倍的降采样。利用这种从细到粗的尺度分级，模型得以同时捕获小物体细节和大物体轮廓。这一配置在常见检测场景中表现稳定，因此被沿用。

不过，放到无人机航拍图像中时，情况有所不同。图像中的目标经过多次下采样后，边缘、纹理和位置信息会逐步减弱。而相较于大目标，小目标由于自身像素占比较少，在 P3 及更深层特征图中更容易因下采样压缩而出现有效信息不足的问题。如果仍主要依靠 P3 以及更深层特征图进行预测，模型能够利用的小目标细节信息就会比较有限，容易出现漏检或定位不准确的情况。

为了解决该问题，本文在原有的三尺度检测结构中加入 P2 检测层，让检测头由 P2、P3、P4 和 P5 一起参与预测。如表 3.1 所示，以输入尺寸 640×640 为例，P2 对应的特征图尺寸为 160×160 ，下采样倍率为 4。与 P3 相比，P2 保留了更高的空间分辨率，浅层细节也更完整，更适合让极小目标和密集小目标参与后续检测。

在结构实现上，本文在 YOLOv8 颈部网络中增加一条高分辨率特征分支，并将其输出送入新增的 P2 检测头。这样可以使包含更多细节信息的高分辨率特征图参与预测，从而提升模型对无人机航拍小目标的检出和定位能力。

表 3.1 各特征图属性表

特征图名称	特征图大小	下采样倍率
P2	160×160	4
P3	80×80	8
P4	40×40	16
P5	20×20	32

3.2 多尺度卷积 MKIR

无人机图像中的小目标通常像素占比较低，自身特征有限。如果骨干网络只采用单一尺度卷积，提取到的信息相对单一，难以同时保留目标局部细节并补充周围区域线索。为此，本文在 YOLOv8 骨干网络中引入 MKIR^[34]多尺度卷积模块，通过不同感受野分支并行提取特征，不同感受野提取的特征能形成互补，在保留局部细节的同时补充邻域上下文信息，以提升主干网络的多尺度特征提取能力，使提取的特征更丰富，从而改善小目标特征表达不足的问题。

另外，无人机航拍图像里，目标尺寸变化比较明显，有时一张图中会同时出现很小的目标和相对较大的目标。若网络只依赖单一尺度卷积，感受野受限，进而使提取到的特征范围比较有限，处理不同大小目标时容易顾此失彼。MKIR 通

过设置多个不同感受野的分支并行提取特征，能够让网络同时看到局部和较大范围的信息，因此对目标尺度变化较大的场景更具有适应性。

MKIR 模块的结构如图 3.2 所示，输入特征首先经过一次 1×1 卷积映射扩充通道；之后，特征被送入 1×1 、 3×3 和 5×5 三个并行分支，从不同尺度、不同感受野上提取信息。分支处理结束后，各分支输出在通道维度进行拼接，再通过通道重排增强分支之间的信息交互，最后利用 1×1 卷积对融合结果进行压缩和整合，得到模块输出。

需要说明的是，MKIR 中的三个并行分支采用的是深度卷积（Depthwise Convolution, DWConv），而不是普通卷积。深度卷积会对每个输入通道分别进行空间卷积，因此参数量和计算开销相对更小，更适合放在这种多分支结构中使用。其中， 1×1 分支主要用于保留当前特征， 3×3 分支负责提取局部细节信息， 5×5 分支则能够覆盖更大范围的区域，用于补充邻域上下文信息。与串联方式相比，并行结构可以同时从多个尺度上处理输入特征，更适合无人机航拍图像中目标尺度变化明显、小目标特征较弱的情况。

在式（3.1）至式（3.8）中详细说明了特征图经过 MKIR 模块处理的全过程。其中， X 表示输入特征图， E 表示初步映射后的中间特征， B_1 、 B_2 和 B_3 分别表示三个并行分支的输出， F 表示拼接后的融合特征， $\tilde{F}$ 表示通道重排后的特征表示， Y 为模块最终输出。由于深度卷积在分支内部不直接进行跨通道交互，所以在拼接后引入通道重排和 1×1 卷积，以促进不同分支与不同通道之间的信息融合，使多尺度特征得到进一步整合。

除了上述设计外，MKIR 模块中还引入了残差连接，将输入特征与融合后的输出特征进行相加。这样做有助于增强特征传递的稳定性，并缓解深层网络中的信息退化问题。与此同时，模块中各分支后均保留 BN 和 SiLU 操作，其中 BN 用于减小特征分布波动对训练过程的影响，SiLU 则具有更平滑的非线性映射特性，更有利于保留一部分较弱的响应信息。对于无人机航拍图像中的小目标检测任务而言，这种设置有助于增强模块对细节特征的表达能力，同时也与 YOLOv8 整体网络的激活方式保持一致。

总体来看，MKIR 模块通过并行多尺度深度卷积、特征拼接、通道重排和残差连接等设计，在较低额外开销下融合不同感受野的信息。该模块既能够保留边缘、纹理等局部细节，又能够补充目标周围区域的上下文信息，从而增强主干网络的多尺度特征提取能力。




图 3.2 多尺度卷积 MKIR 模块结构图

$$X \in R^{C \times H \times W} \quad (3.1)$$

$$E = \text{Conv}_{1 \times 1}(X) \quad (3.2)$$

$$B_1 = \text{DWConv}_{1 \times 1}(E) \quad (3.3)$$

$$B_2 = \text{DWConv}_{3 \times 3}(E) \quad (3.4)$$

$$B_3 = \text{DWConv}_{5 \times 5}(E) \quad (3.5)$$

$$F = \text{Concat}(B_1, B_2, B_3) \quad (3.6)$$

$$\tilde{F} = \text{Shuffle}(F) \quad (3.7)$$

$$Y = \text{Conv}_{1 \times 1}(\tilde{F}) + X \quad (3.8)$$

本文把 MKIR 模块安排在 Backbone 阶段，具体来说，MKIR 分别放置在 P2、P3 和 P4 阶段的 C2f 模块之后，以及 P5 阶段的 SPPF 模块之后。这样放置主要是由于主干网络负责基础特征提取工作，P2、P3、P4 和 P5 各尺度特征图在送入 Neck 融合之前，保留着不同层级的目标信息。本文希望在主干各阶段对各个尺度的特征图进行多尺度特征增强，使其在进入颈部网络之前已经具备不同感受野下的特征表达。如果仅在主干的深层或者 Neck 阶段利用不同感受野提取特征，部分信息可能会在连续的下采样过程中减弱，后续进行补充会比较困难。本文把 MKIR 加入

到 Backbone 里，在特征提取阶段能够获得不同感受野的特征，这给后续的特征融合和检测预测提供了更加充分的特征支持。

3.3 三重注意力模块

P2 检测层和 MKIR 模块分别增强了模型对小目标细节的利用和多尺度特征提取的能力，但是在无人机航拍图像中，小目标与背景区分度较低，背景干扰较强的问题仍然存在。特别是在道路、建筑、树木和阴影等复杂背景条件下，融合后的特征中仍然可能包括较多无关响应，小目标相关信息更容易受到削弱。本文在颈部特征融合后的关键节点加入三重注意力模块（Triplet Attention）^[35]，让网络能够更加突出目标区域和其重要信息，并且对无关背景特征产生的干扰进行抑制，进而提高复杂场景中小目标的识别和定位能力。




图 3.3 三重注意力模块结构图

三重注意力模块包含三个并行的分支，如图 3.3 所示，分别在 H-W、C-W 和 C-H 三个二维平面上对输入特征进行加权。设输入特征图为 $X \in R^{C \times H \times W}$ ，其中 C 、 H 和 W 分别表示通道数、高度和宽度。左侧分支直接对原始特征图进行处理，对应 H-W 平面；另外两个分支则先对输入特征进行维度置换，分别在 C-W 和 C-H 平面上生成对应的注意力权重。这样处理以后，模块不只会注意到空间位置上更重要的区域，还能把各个通道在宽度方向和高度方向上的响应差别体现出来。

以 H-W 分支为例, 该分支在不改变输入特征排列方式的情况下计算空间注意权重。具体来说, 模块会先在通道维度上分别做最大池化和平均池化处理, 得到 2 个 $(1 \times H \times W)$ 的特征图, 用来从不同角度提取输入特征在空间位置上的响应; 再将二者拼接为 $(2 \times H \times W)$ 的压缩表示。在此基础上, 通过卷积和 Sigmoid 函数生成对应的空间注意权重, 并将其与输入特征逐元素相乘, 从而对重要区域进行强化, 对背景及无关响应进行抑制。

C-W 分支和 C-H 分支的处理过程与 H-W 分支基本一致, 不同之处在于二者首先对输入特征进行维度置换。对于 C-W 分支, 输入特征由 $(C \times H \times W)$ 变换为 $(H \times C \times W)$, 在完成池化、拼接、卷积和 Sigmoid 操作后, 最终得到尺寸为 $(1 \times C \times W)$ 的各个通道在宽度方向上的注意力权重, 并与输入特征逐元素相乘; 对于 C-H 分支, 输入特征由 $(C \times H \times W)$ 变换为 $(W \times H \times C)$, 经过相同的处理后, 生成尺寸为 $(1 \times H \times C)$ 的各个通道在高度方向上的注意力权重, 同样与原始输入特征相乘。两个分支在完成上述操作后再分别恢复到原始维度。各分支处理结束后, 输出特征的尺寸保持一致, 随后通过取均值的方式将三部分结果合并, 得到三重注意力模块的最终输出。

与仅在空间维度或通道维度上单独分配权重的注意力机制相比, 三重注意力能够从不同角度对特征图进行筛选和增强, 更有利于突出目标相关区域并抑制复杂背景中的无关响应。对于无人机航拍图像中目标尺寸小、目标显著性不足且背景干扰较强的情况, 该模块通过对颈部多尺度融合后的特征图进行通道与空间联合加权, 进一步突出目标相关信息, 并抑制背景干扰, 从而提升模型对航拍小目标的感知与识别效果。

3.4 基于部分卷积的 C2f_PConv 模块

在模型引入 P2 检测层、MKIR 模块和三重注意力模块后, 其对小目标细节信息、多尺度特征以及关键区域的表达更为充分, 但多个结构叠加也会带来参数量和计算量的增加。为避免模型规模继续扩大, 本文在保持检测性能的前提下, 对部分 C2f 模块进行轻量化调整, 引入部分卷积^[36]思想并构建 C2f_PConv 结构。该结构通过减少部分冗余卷积操作, 控制模型参数规模和整体复杂度。

部分研究指出卷积后的特征在部分通道之间往往具有一定相似性^[37], 即卷积结果通道方向上存在一定冗余, 因此可以不让全部通道都进行完整的空间卷积。与标准卷积对全部输入通道同时进行空间卷积不同, 部分卷积只对其中一部分通道执行卷积计算, 其余通道直接保留并参与后续特征融合。这种方式在保留部分原始信息传递路径的同时, 减少了卷积过程中的冗余计算, 从而对模型规模起到一定调节作用。基于此, 本文将部分卷积融入 C2f 模块, 构建 C2f_PConv 结构, 使模型在保持主要特征提取能力的同时, 降低不必要的参数开销, 并将整体复杂度控制在相对合理的范围内。

本文采用 PConv、FasterBlock 和 C2f_PConv 逐层构建的方式，将部分卷积思想嵌入 YOLOv8 的 C2f 模块中，下面介绍如何逐级构造 C2f_PConv 模块。其中，PConv 的基本结构如图 3.4 所示。在这一结构里，并不是所有通道都会一起参与 3×3 卷积计算。部分通道会进入卷积分支提取局部空间信息，其余通道则继续保留原有特征；等卷积分支处理完成后，再与未参与卷积的那部分特征在通道维度上合并输出。这样处理以后，一些原始信息能够直接保留下来，同时也避免了把全部通道都送入卷积所带来的额外计算。




图 3.4 部分卷积 PConv 运算示意图

图 3.5 展示了 FasterBlock 的结构。为了减少不必要的卷积计算，该模块的处理流程是：先经由 PConv，一部分通道做卷积运算，另一部分通道则不做任何操作、直接向后传递。接着，特征图会被送入两个 1×1 卷积层来完成通道维度的调整。其中，第一个 1×1 卷积把批量归一化与激活函数封装在一起，用于扩增通道数量、引入非线性变化，并促进卷积通道与保留通道之间的信息交互；第二个 1×1 卷积则将通道数压缩回原始数值，保证模块的输入输出尺寸不变。模块末端保留残差连接，把处理过的特征和输入特征相加，这样可以保留部分原始特征。由此可知，FasterBlock 通过部分卷积、 1×1 逐点卷积和残差连接完成特征提取，是一种轻量级特征提取单元。




图 3.5 FasterBlock 结构图

在此基础上，图 3.6 进一步给出了 C2f_PConv 的整体结构。该模块沿用了原始 C2f 的基本框架，其主要区别在于将内部用于特征提取的 Bottleneck 单元替换为轻量级特征提取单元 FasterBlock，从而将部分卷积思想嵌入 C2f 结构之中。在保留 C2f 原始结构的同时，C2f_PConv 能够减少局部卷积操作中的冗余开销，并完成更加高效的特征提取与融合。




图 3.6 C2f_PConv 结构图

通过上述构造方式，C2f_PConv 在保留 C2f 模块原有特征传递和中间信息融合结构优势的基础上，引入部分卷积以减少局部卷积操作中的冗余参数，使模型在保持主要特征提取能力的同时，对整体参数规模和复杂度进行适度调节。对于本文所构建的无人机航拍小目标检测模型而言，该设计有助于在前述改进增强特征表达能力的基础上，进一步缓解模型结构叠加带来的参数增长问题，使整体复杂度保持在相对可控的范围内。

需要说明的是，本文并未将网络中的所有 C2f 模块统一替换为 C2f_PConv，而是仅在主干网络深层阶段及颈部末端的部分位置进行局部替换。其原因在于，浅层特征图分辨率较高，主要承担小目标边缘、纹理和位置信息的保留任务。若在这些高分辨率层过多引入部分卷积，虽然能够减少部分参数冗余，但也可能削弱浅层细粒度信息的完整表达，不利于极小目标特征的保留。相比之下，主干深层和颈部末端的特征层语义信息更强，且通道数更多。由于卷积参数量主要受卷积核大小及输入、输出通道数影响，因此在通道数较多的位置引入 C2f_PConv，更有利于减少冗余卷积参数，并在尽量保持主要特征提取能力的基础上控制模型复杂度。基于上述考虑，本文采用局部替换而非全局替换的方式，以兼顾小目标细节保留和整体复杂度调节的需求。

3.5 本章小结

本章说明了 YOLOv8m 的改进思路和实现方式。对于小目标在多次下采样后细节信息容易减弱的问题，本文在检测头中加入 P2 检测层，让包含更多细节信息的高分辨率特征参与预测。为改善小目标特征不足的问题，并增强模型对尺度变化目标的适应能力，本文将 MKIR 模块加入骨干网络，利用不同感受野分支提取特征，在保留局部细节的同时补充周围区域信息，以提升主干网络的多尺度特征提取能力。在复杂背景下，小目标容易受到无关信息干扰，本文在颈部特征融合阶段加入三重注意力机制，用于突出目标相关区域，并减弱无关背景的影响。另外，为避免多种改进叠加后带来过多参数量和计算开销，本文在部分 C2f 模块中加入 C2f_PConv 结构，对模型复杂度进行适当控制。经过上述改进，本文从检测头、骨干网络、特征融合和结构轻量化四个方面对模型进行了有针对性的调整。下一章将在此基础上开展实验，并结合实验结果对改进模型的性能进行分析。

第 4 章 实验设计与结果分析

4.1 实验配置

本文实验是在云端深度学习服务器上完成，所使用实验环境如表 4.1 所示。

表 4.1 实验配置表

名称	配置
操作系统	Ubuntu 20.04.5 LTS
CPU	Intel Xeon Gold 6430
内存	1.0TiB
GPU	NVIDIA GeForce RTX 4090 24GB
Python	3.10.19
Pytorch	2.6.0
CUDA	12.4
cuDNN	9.1.0

表 4.2 给出了本文训练所采用的主要超参数。对于基线模型、本文改进模型及消融实验，各项训练参数保持一致，以保证结果具有可比性；对于对比实验中的其他模型，在统一数据集划分和评价指标的前提下，尽量参考其原论文或公开代码中的训练设置开展实验。表中，`imgsz` 表示输入图像尺寸，`batch` 表示批大小，`workers` 表示数据加载线程数，`lr0` 表示初始学习率，`momentum` 表示动量系数，`warmup epochs` 表示预热轮数，`close mosaic` 表示关闭 Mosaic 增强的轮次，`amp` 表示启用混合精度训练，`patience` 表示早停等待轮数，模型在验证集上若连续 `patience` 轮性能不再增长，训练就会被提前叫停。

表 4.2 超参数设置表

超参数	取值
<code>epochs</code>	130
<code>imgsz</code>	640
<code>batch</code>	12
<code>workers</code>	2
<code>optimizer</code>	auto
<code>lr0</code>	0.01
<code>momentum</code>	0.937
<code>warmup_epochs</code>	3.0
<code>close_mosaic</code>	10
<code>amp</code>	True
<code>paitence</code>	25

4.2 数据集与评价指标

4.2.1 数据集介绍

本文实验采用 VisDrone 数据集。该数据集由无人机在真实场景下采集，图像中包含道路、居民区、商业区等多种环境，也覆盖了晴天、阴天和弱光等不同拍摄条件。由于无人机拍摄高度和角度不断变化，数据集中目标普遍较小，且常伴随密集分布、遮挡和背景干扰等情况，对模型的检测性能要求较高。

本文实验使用 VisDrone 数据集中的目标检测子集。该数据集在本文中沿用官方给出的划分方案，其中训练集、验证集和 test-dev 测试集分别包含 6471 张、548 张和 1610 张图像，总计 10209 张。训练阶段使用训练集更新模型参数，验证集用于训练过程中的性能监控与参数调整，test-dev 测试集则用于最终性能评估和对比实验结果统计。数据集中共标注 10 类目标，分别为 pedestrian、people、bicycle、car、van、truck、tricycle、awning-tricycle、bus 和 motor。

与普通自然图像数据集相比，VisDrone 中的目标尺寸更小，场景变化也更明显。特别是在车辆、行人等类别中，远距离目标和密集目标占比较高，对模型的细节提取、多尺度特征利用和定位能力都有较高要求。如图 4.1 为 VisDrone 数据集部分图片样本。




图 4.1 VisDrone 数据集部分样本图

从图 4.2 可以看出，VisDrone 数据集中不同类别目标的样本数量分布并不均衡。其中，car、pedestrian 和 motor 等样本多，占比较大，而 tricycle、awning-tricycle、bus 等类别的样本数量少，占比较小。这表明该数据集类别不均衡。在模型训练过程中，样本数量较多的类别往往更容易被充分学习，而样本数量较少的类别由于可供学习的特征信息有限，导致模型训练过程中学习不充分，从而影响整体检测性能。




图 4.2 VisDrone 数据集各类目标样本分布图

由图 4.3 可以看出，绝大多数目标框集中在坐标原点附近，说明数据集中的目标尺寸普遍较小，小目标占据较高比例。同时，图中仍存在少量宽度和高度较大的目标，表明数据集中目标尺度变化较为明显，具有较强的尺度差异。无人机航拍图像通常具有拍摄高度高、目标密集、背景复杂以及遮挡现象明显等特点，在这种情况下，小目标由于所含像素信息有限，其边缘、纹理和语义特征往往不够突出，容易在特征提取和特征融合过程中被弱化，进一步拉高了目标被准确检出的困难程度。




图 4.3 VisDrone 数据集样本长宽散点图

综合来看，VisDrone 数据集不仅具有类别分布不均衡的特点，同时还表现出小目标占比较高和目标尺度变化明显等特征。这些特点对检测模型的细粒度特征

提取能力、多尺度信息融合能力以及小目标定位能力提出了更高要求。因此，针对无人机航拍视角下的小目标检测任务，有必要从浅层细节保留、多尺度特征提取以及特征表达优化等方面对基线模型进行改进，以提升模型在复杂场景下的检测效果。

4.2.2 目标检测评价指标介绍

为了更全面地判断模型在无人机航拍小目标检测任务中的表现，本文不只关注检测结果是否准确，还考虑模型本身的规模和计算开销。基于这一点，本文从检测性能和模型复杂度两个方面对实验结果进行评价。其中 Precision、Recall、mAP@0.5 和 mAP@0.5:0.95 用于衡量模型的检测效果，Params 和 GFLOPs (Giga Floating-point Operations) 则用于反映模型的参数规模与计算开销。在统计检测结果时，若模型给出的类别和位置都与真实目标匹配，则记为真正例 (True Positive, TP)；若模型错误地把背景或其他类别判断为目标，则记为假正例 (False Positive, FP)；若图像中真实存在目标但模型未能检出，则记为假负例 (False Negative, FN)。

Precision 用于衡量预测结果中真实目标所占的比例。当模型输出的检测框中错误结果较多时，该值会下降，因此它可以反映误检情况的多少。式 (4.1) 中，TP 为正确匹配真实目标的检测结果数量，FP 为被模型判定为目标但未能与真实目标匹配的检测结果数量。

$$Precision = \frac{TP}{TP + FP} \quad (4.1)$$

Recall 关注的是真实目标中有多少检测到。如果目标在图像中是真实存在的，但模型检测过程中遗漏了目标，那么 Recall 值就会下降。其计算方式如式 (4.2) 所示。该指标越高，说明漏检现象越少，模型对图像中真实目标的检测更充分。TP 表示被模型正确识别出的目标数，FN 表示模型在检测过程中遗漏的目标数量，即图像中实际存在但没有被检出的部分。

$$Recall = \frac{TP}{TP + FN} \quad (4.2)$$

仅看 Precision 或 Recall 中的某一个指标，往往还不足以完整反映检测效果。因此，通常使用 AP (Average Precision) 和 mAP 对模型检测性能进行综合评价。对于某一类别来说，AP 可以理解为该类别 Precision-Recall 曲线下方的面积，如式 (4.3) 所示，其中， $P(R)$ 表示 Precision 关于 Recall 的函数关系。

$$AP = \int_0^1 P(R) dR \quad (4.3)$$

mAP 则是在各类别 AP 基础上求平均得到的结果，其计算方式如式 (4.4) 所示， AP_i 表示第 i 类目标的平均精度， N 表示类别总数。因此更适合用来描述模型在整个数据集上的综合检测水平。

$$mAP = \frac{1}{N} \sum_{i=1}^N AP_i \quad (4.4)$$

本研究采用 mAP 作为主要评价标准，具体统计两个版本：mAP@0.5 和 mAP@0.5:0.95。其中，前者固定 IoU 阈值在 0.5 处，计算各类别 AP 的平均值，用于反映模型的基础检测性能。后者在 0.5 到 0.95 之间按照 0.05 的间隔设置了多个 IoU 阈值，然后对不同阈值下的结果取平均。和单一 IoU 阈值比较，mAP@0.5:0.95 对预测框和真实框重合程度的要求更高，所以更能反映定位的质量。在进行无人机航拍小目标检测时，mAP@0.5 代表了目标是否被检测到，mAP@0.5:0.95 反映了检测框位置的准确程度。

本文在比较检测结果时，除了关注精度，还把 Params 和 GFLOPs 作为模型复杂度的参考指标。Params 反映的是模型中可训练参数的多少，GFLOPs 则反映一次前向推理所需的计算量。一般来说，这两个数值越大，模型对存储和算力的占用也越高。

4.3 对比实验

本文选择 Faster R-CNN、RetinaNet 等经典检测模型，YOLOv5m、YOLOv8m、YOLOv10m、YOLOv11m 等通用 YOLO 系列模型，还有 TPH-YOLO-L^[21]、Drone-YOLO^[23]、PCPE-YOLO^[29]和 HIC-YOLO^[38]等针对无人机场景的改进模型，进行对比实验，以检验本文方法的整体检测效果。

表 4.3 表明，该表中的每行对应一种对比检测模型，并在检测精度和模型复杂度这两个方面进行了比较。P、R、mAP@0.5 和 mAP@0.5:0.95 是性能评价指标，Params 和 GFLOPs 用来反映模型参数规模和计算开销，各项指标都在 4.2.2 节中进行了详细说明。实验结果表明，本文方法在多数精度指标上均取得了较好的表现，其中 mAP@0.5 达到 40.3%，mAP@0.5:0.95 达到 23.8%，说明改进模型在目标检出能力和定位精度方面均具有较强竞争力。

相比于传统的检测网络（如 Faster R-CNN、RetinaNet），本文提出的改进 YOLOv8 具有全方位的优势，在技术方面有许多改进之处。虽然 Faster R-CNN 和 RetinaNet 已建立良好的检测框架，但是在 VisDrone 这类复杂环境中，由于目标变化及尺寸较小等问题，这两者都有一定局限性。由表 4.3 可知，改进后的 YOLOv8 在精度（Precision）、召回率（Recall）、mAP@0.5 以及 mAP@0.5:0.95 方面均优于这两个模型，且在模型大小以及计算开销上也低于两者。

相比通用 YOLO 系列模型，本文方法同样有较大提升。相较于基线模型 YOLOv8m，本文方法的 Precision 由 47.1%提升至 51.0%，Recall 由 36.8%提升至 41.0%，mAP@0.5 由 35.1%提升至 40.3%，mAP@0.5:0.95 由 20.7%提升至 23.8%。与 YOLOv5m、YOLOv10m、YOLOv11m 和 YOLOv26m 相比，本文方法在各项精度指标上也保持领先，说明所采用的 P2 检测层、多尺度卷积和注意力机制等改进

对无人机场景具有较好的适应性。虽然 YOLOv7 的 $mAP@0.5$ 略高于本文方法，但其参数量和计算量明显更大；本文方法的 $mAP@0.5$ 与其差距较小，而 $mAP@0.5:0.95$ 更高，因此整体检测表现更均衡。

从无人机目标检测改进模型的对比结果来看，TPH-YOLO-L 和 Drone-YOLO 等方法虽然也针对航拍小目标进行了结构优化，但本文方法在 Precision、Recall、 $mAP@0.5$ 和 $mAP@0.5:0.95$ 四大性能指标上仍取得了更高结果。与 PCPE-YOLO 和 HIC-YOLO 相比，本文方法在 Precision、Recall 和 mAP 指标上也均有优势。

在模型复杂度方面，本文方法的参数量为 21.9M，处于所有对比实验模型中的中等水平，与 YOLOv5m、YOLOv11m 和 PCPE-YOLO 较为接近。虽然计算量并不算低，但仍处于可接受范围。综合来看，本文方法并不是单纯依靠增大模型规模来换取精度提升，而是在保持模型复杂度相对合理的基础上，提高了无人机航拍图像中小目标的检测精度，较好地兼顾了检测性能与运行开销。

表 4.3 对比实验表

模型	Precision $\uparrow$	Recall $\uparrow$	$mAP@0.5 \uparrow$	$mAP@0.5:0.95 \uparrow$	Params (M) $\downarrow$	GFLOPs $\downarrow$
Faster R-CNN	33.5	25.7	20.2	10.6	41.4	134.4
Retinanet	42.8	32.7	28.2	16.6	36.5	210.0
YOLOv5m	44.1	34.3	32.0	17.9	20.8	48.0
YOLOv7	52.4	42.8	40.8	22.5	36.9	104.7
YOLOv8m	47.1	36.8	35.1	20.7	25.9	79.1
YOLOv10m	49.5	36.3	35.3	20.6	16.5	64
YOLOv11m	49.3	38.3	37.4	22.3	20.1	68.5
YOLOv26m	49.7	38.9	35.5	20.4	21.9	75.4
TPH-YOLO-L	50.6	36.1	35.4	20.1	60.4	145.7
HIC-YOLO(s)	43.8	38.7	35.9	19.9	9.3	30.8
Drone-YOLO(m)	50.2	38.7	38.1	21.9	33.9	99.9
PCPE-YOLO	48.6	38.7	37.4	22.1	19.5	77.4
Ours	51.0	41.0	40.3	23.8	21.9	99.6

4.4 消融实验

本节通过消融实验来评估不同改进模块在无人机小目标检测任务上各自能起到多大作用，实验选用的数据集是 VisDrone，具体数值记录在表 4.4。

需要说明的是，原始 YOLOv8 采用 P3、P4、P5 三尺度检测结构，本文首先引入 P2 检测层，将其扩展为 P2、P3、P4、P5 四尺度检测结构，并完成了 P2 检测层相对基线模型的独立验证。后续各模块的设计与实验均在此四尺度结构基础上展开，本文最终保留的 MKIR 模块、三重注意力模块和 C2f_PConv 结构也在该结构

上完成验证。因此，消融实验以带 P2 的 YOLOv8 作为固定基线，逐一引入其余模块进行对比，以评估各模块在四尺度检测结构下的实际贡献。

从表 4.4 可以看出，在基线模型中引入 P2 检测层后，模型的 $mAP@0.5$ 由 35.1% 提升至 37.3%，提高了 2.2 个百分点； $mAP@0.5:0.95$ 由 20.7% 提升至 22.0%，提高了 1.3 个百分点；Precision 和 Recall 也分别从 47.1% 和 36.8% 提高到 49.1% 和 38.6%。这表明在加入高分辨率检测层之后，网络可以更充分利用浅层特征中的边缘、纹理和位置信息，有利于增强模型对小尺度目标的检测能力。

在带有 P2 的 YOLOv8 中引入 MKIR 模块，模型的 Precision、Recall、 $mAP@0.5$ 和 $mAP@0.5:0.95$ 分别达到 51.6%、39.7%、39.7% 和 23.3%， $mAP@0.5$ 和 $mAP@0.5:0.95$ 较带有 P2 的 YOLOv8 分别提高 2.4 和 1.3 个百分点，增幅比较明显。分析发现，MKIR 利用不同感受野分支进行特征提取，在保留局部细节的同时补充周围区域信息，有助于提升主干网络的多尺度特征提取能力，从而改善小目标特征表达不足的问题。

在带有 P2 的 YOLOv8 基础上加入 Triplet Attention（三重注意力）模块之后，模型的 Recall、 $mAP@0.5$ 和 $mAP@0.5:0.95$ 分别达到 39.2%、38.2% 和 22.6%。尽管提高幅度比 MKIR 小，但是各项指标和 P2 模型相比仍然有增长，表明三重注意力机制可以颈部多尺度融合后的特征进行进一步筛选，突出目标相关区域，并且减少复杂背景造成的干扰，对小目标检测起到一定促进作用。

在带有 P2 的 YOLOv8 引入 C2f_PConv 后，模型 $mAP@0.5$ 和 $mAP@0.5:0.95$ 分别达到 37.9% 和 22.5%，比带有 P2 的 YOLOv8 有稍微提高。参数量从 25.1M 减少到 17.6M，GFLOPs 从 98.0G 降低到 85.5G，复杂度降低比较明显。分析表明，C2f_PConv 在减少冗余卷积操作、控制参数量和计算量时，没有削弱模型的主要特征提取能力反而还提升了模型精度。这主要是因为本文并没有对浅层 C2f 进行替换，而是将 C2f_PConv 放在骨干网络较深层和颈部末端等位置。这些位置的特征图语义信息更强，通道数也更多，冗余相对比较明显，适合做轻量化处理；而浅层 C2f 则继续保留原有的特征提取方式，从而尽量避免对小目标所需的细节信息造成影响。因此，C2f_PConv 在降低复杂度的同时，也减少了深层特征图中部分重复特征的影响，使模型能够较好地保持甚至略微提升检测性能。

就增量结果而言，在 P2 和 MKIR 基础上继续加入 Triplet Attention 模块后，模型的 Recall 提高到 41.1%， $mAP@0.5$ 和 $mAP@0.5:0.95$ 分别达到 39.9% 和 23.5%。本文在该基础上引入 C2f_PConv，模型得到最佳结果， $mAP@0.5$ 达到 40.3%， $mAP@0.5:0.95$ 达到 23.8%，参数量也下降到 21.9M。说明本文所提出的几项改进并不是简单堆叠，而是在高分辨率特征保留、多尺度特征提取、关键区域增强和复杂度调节等方面形成了较好的协同作用。

综上，消融实验证明了本文提出的各项改进均对提高模型检测性能起到积极作用。与基线模型相比，最终模型的 $mAP@0.5$ 由 35.1% 提升至 40.3%，提高了 5.2

个百分点； $mAP@0.5:0.95$ 由 20.7% 提升至 23.8%，提高了 3.1 个百分点；Precision 和 Recall 分别提高了 3.9 和 4.2 个百分点。同时，模型参数量由 25.9M 下降至 21.9M，减少了 4.0M，降幅约为 15.4%。这表明改进后的 YOLOv8 模型在提升无人机航拍图像小目标检测性能的同时，也将整体复杂度控制在了相对合理的范围内。

表 4.4 消融实验表

P2	MKIR	Triplet Attention	C2f_P Conv	Precision	Recall	$mAP@0.5$	$mAP@0.5:0.95$	Params (M)	GFLOPs
×	×	×	×	47.1	36.8	35.1	20.7	25.9	79.1
√	×	×	×	49.1	38.6	37.3	22.0	25.1	98.0
√	√	×	×	51.6	39.7	39.7	23.3	29.2	112.1
√	×	√	×	50.2	39.2	38.2	22.6	25.1	98.6
√	×	×	√	49.6	39.1	37.9	22.5	17.6	85.5
√	√	√	×	50.9	41.1	39.9	23.5	29.3	112.7
√	√	√	√	51.0	41.0	40.3	23.8	21.9	99.6

4.5 可视化分析

4.5.1 训练过程可视化分析

图 4.4 和图 4.5 展示了基线模型与本文改进模型在训练阶段的各项指标变化曲线。整体来看，两组实验都能够完成正常训练，曲线变化没有出现明显异常，说明模型训练过程较为稳定。

从损失函数曲线来看，模型训练集和验证集上的 box_loss 、 cls_loss 与 dfl_loss 三类损失均随训练轮次增多而减小，后期变化幅度明显放缓，表明模型对目标位置、类别以及边界框分布的学习逐渐稳定下来。与此同时，Precision、Recall、 $mAP@0.5$ 和 $mAP@0.5:0.95$ 等指标总体呈上升趋势，并在训练后期趋于平稳，说明模型性能已基本收敛。

将两组曲线进行对比可以发现，改进模型在后期的指标表现整体更好，Precision、Recall 和 mAP 相关指标均高于基线模型，同时曲线波动相对更小。由此可以观察到，改进后的模型在稳定训练的前提下，其针对无人机航拍小目标的特征提取与检测能力均获得了提升。

需要说明的是，本文训练过程中设置了早停机制，具体机制在 4.1 节已经阐述。因此，基线模型与改进模型的实际停止轮次并不完全相同。这种差异主要与两者收敛速度和验证集指标变化情况有关，不影响后续实验结果的比较。总体来看，改进模型在训练稳定性和最终检测效果上均表现得更佳。




图 4.4 改进前模型训练验证过程曲线图




图 4.5 改进后模型训练验证过程曲线图

4.5.2 各类别检测性能可视化分析

从各检测类别的精度这一维度出发,对基线模型与改进模型做一个比较,本文展示了这两个模型在 VisDrone 数据上的 P-R 曲线,并统计了各类别 AP 值,如表 4.5 和图 4.6 所示。P-R 曲线可以直观地反映出模型在不同类别上精确率和召回率的变化情况,表格和柱状图进一步说明了各个类别 AP 值存在的具体差异。


观察图 4.6 的 P-R 曲线:改进模型在每个类别上的曲线都朝右上方偏移。各类别曲线的下方面积更大,说明其 AP 值整体好于基线模型。此外,表 4.5 与图 4.7 进一步显示,改进模型在大多数类别上均取得了不同程度的性能增长。行人 AP 值从 30.1%提升到 38.5%,人群从 16.8%上升到 24.4%,汽车从 74.2%上升到 79.5%,摩托车从 32.6%上升到 38.9%,这些类别提升较为明显。同时,遮阳三轮车、三轮

车、自行车等相对难检的类别也有一定提高,说明本文方法在各个类别检测的性能上均取得了较为明显的提升。

从整体结果来看,模型平均 AP 从 35.1%提高到 40.3%,提高 5.2 个百分点。表明模型的整体检测性能提升。类别检测结果进一步说明本文改进的方法在无人机小目标检测任务中是有效的。

表 4.5 各类别平均精度改进前后对比表

模型	行人	人群	自行车	汽车	箱式 货车	卡车	三轮	遮阳 三轮	公交	摩托车	全部
原始	30.1	16.8	12.6	74.2	40.2	43.7	22	18.9	59.8	32.6	35.1
Ours	38.5	24.4	15.3	79.5	45.6	47.2	24.8	25.6	62.8	38.9	40.3



(a)改进前模型 P-R 曲线

(b)改进后模型 P-R 曲线

图 4.6 YOLOv8 模型改进前后 P-R 曲线对比图




图 4.7 模型改进前后各类目标 AP50 柱形对比图

4.5.3 检测结果可视化分析

为了更为直观地对比模型改进的效果，现从检测结果的角度对比分析。如图 4.8 所示，图中左、右两部分分别给出了基线模型与本文改进模型的检测结果。结合图中圆圈标注区域可以看出，在无人机俯视场景下，远距离目标和密集分布的小目标更容易出现漏检现象，尤其是在有遮挡、目标密集、夜间低照度的情况下，基线模型对部分尺度较小、显著性较弱的目标检测结果较差，存在不同程度的漏检问题。相比之下，本文改进模型在相同场景下能够检测出更多原本未被识别的小目标，圆圈区域内的被模型检测出来的目标数量明显增多，说明模型对小目标特征提取能力有所加强，能够更有效地减少漏检现象，体现出更好的实际检测效果。





图 4.8 模型改进前后检测结果对比图

4.5.4 检测结果热力图分析

为对比模型关注区域的差异，本文采用 Grad-CAM++ (Gradient-weighted Class Activation Mapping++) 工具进行热力图可视化分析，该工具可以显示模型重点关注图像中的哪些区域。由图 4.9 可以看出，基线模型虽然能够对部分目标产生响应，但在目标密集、尺度较小或背景较复杂的区域中，关注分布相对分散，对部分小目

标的响应不够明显。相比之下,改进模型在车辆、行人等目标位置的响应更加集中,远处小目标和密集目标在热力图中也更加明显,同时对部分无关背景区域的响应有所减弱。这表明改进后的模型能够更有效地关注目标相关区域,对小目标特征的提取能力有所增强,与前文定量实验结果基本一致。



(a) 改进前效果

(b) 改进后效果

图 4.9 模型改进前后热力图对比图

4.6 本章小结

本章围绕改进模型的实验结果进行了分析。首先介绍了实验环境、数据集和评价指标,并在 VisDrone 数据集上完成了对比实验、消融实验和可视化分析。实验结果表明,改进后的模型在无人机航拍小目标检测任务中取得了较好的效果,说明新增 P2 检测层、MKIR 模块、三重注意力机制和 C2f_PConv 结构均起到了积极作用。与此同时,可视化结果也进一步说明,改进模型在复杂背景下对小目标的响应更加充分,漏检情况得到一定改善。总体来看,本文方法在提升检测性能的同时,也较好兼顾了模型复杂度。

结论与展望

本文围绕无人机航拍图像中的小目标难以检测的问题，对 YOLOv8m 进行了改进。针对这类图像中目标尺寸小、尺度变化明显、背景干扰较强等特点，本文主要从高分辨率特征利用、多尺度特征提取、注意力机制关键区域增强和模型复杂度调节四个方面进行了研究。

在检测头部分，本文在原有三尺度检测结构基础上增加了 P2 检测层，使浅层高分辨率特征能够更早参与预测。通过这一设计，小目标的边缘、纹理和位置信息保留得更充分，有助于提升模型对极小目标的感知能力。

本文将 MKIR 多尺度卷积模块加入骨干网络部分。该模块通过不同尺度卷积分支并行提取特征，在不过多增加额外开销的前提下，提升了主干网络的多尺度特征提取能力，改善了小目标特征不足的问题，同时增强了模型对尺度变化目标的适应能力。

本文在颈部特征融合阶段引入三重注意力机制，使融合后的特征能够更加突出目标相关区域，并减弱背景干扰带来的影响，从而改善复杂无人机场景下的小目标检测效果。

考虑到前面几项改进会带来一定的参数量和计算量增长，本文进一步将部分卷积思想融入部分 C2f 模块，构建了 C2f_PConv 结构，并将其应用在主干网络深层和颈部末端的部分位置。该改进在尽量保持特征提取能力的基础上，对网络复杂度进行了适当控制。

在 VisDrone 数据集上的实验结果表明，改进后的模型相较于基线 YOLOv8m，mAP@0.5 由 35.1% 提升到 40.3%，mAP@0.5:0.95 由 20.7% 提升到 23.8%。同时，Precision 和 Recall 也有不同程度提高。结合对比实验、消融实验和可视化分析可以看出，本文所采用的改进策略对无人机航拍图像中的小目标检测是有效的。

虽然本文取得了一定结果，但仍有若干方向可以继续探索。一方面，当前方法在远距离、严重遮挡和低对比度目标上的检测能力仍有提升空间。后续可以继续从特征增强和困难样本学习两个方向入手，进一步改善极小目标和复杂样本的检测效果。

另一方面，本文主要在 VisDrone 数据集上进行了验证，虽然结果可以说明模型的有效性，但在不同无人机场景、不同拍摄高度、不同数据分布下的泛化表现仍然需要进一步考察。本文后续可以在更多的无人机数据集上对模型的稳定性和鲁棒性进行验证。

本文在结构里引入 C2f_PConv 对模型复杂度进行调节，不过如果在无人机端或边缘设备上部署，推理效率和资源占用仍然是需要考虑的问题。后续研究可以把

剪枝、量化、蒸馏这些轻量化策略进行结合，既保证检测精度，又能够对模型规模和推理速度进行优化。

综上，本文提出的无人机航拍小目标检测模型仍然需要在精度、复杂度和部署条件上进行整体平衡，该问题也是后续研究可以进一步改进的方向。

参考文献

- [1] Byun S, Shin I K, Moon J, et al. Road Traffic Monitoring from UAV Images Using Deep Learning Networks[J]. Remote Sensing, 2021, 13(20):4027.
- [2] Yang T, Jiang Z, Sun R, et al. Maritime Search and Rescue Based on Group Mobile Computing for Unmanned Aerial Vehicles and Unmanned Surface Vehicles[J]. IEEE Transactions on Industrial Informatics, 2020, 16(12): 7700-7708.
- [3] Li Z, Zhang Y, Wu H, et al. Design and Application of a UAV Autonomous Inspection System for High-Voltage Power Transmission Lines[J]. Remote Sensing, 2023, 15(3): 865.
- [4] Wu X, Li W, Hong D, et al. Deep Learning for Unmanned Aerial Vehicle-Based Object Detection and Tracking: A Survey[J]. IEEE Geoscience and Remote Sensing Magazine, 2021, 10(1): 91-124.
- [5] Liu M, Wang X, Zhou A, et al. UAV-YOLO: Small Object Detection on Unmanned Aerial Vehicle Perspective[J]. Sensors, 2020, 20(8): 2238.
- [6] Zou Z, Chen K, Shi Z, et al. Object Detection in 20 Years: A Survey[J]. Proceedings of the IEEE, 2023, 111(3): 257-276.
- [7] Lowe D G. Distinctive Image Features from Scale-Invariant Keypoints[J]. International Journal of Computer Vision, 2004, 60(2): 91-110.
- [8] Dalal N, Triggs B. Histograms of Oriented Gradients for Human Detection[C]. 2005 IEEE computer society conference on computer vision and pattern recognition (CVPR'05). Ieee, 2005, 1: 886-893.
- [9] Felzenszwalb P F, Girshick R B, McAllester D, et al. Object Detection with Discriminatively Trained Part-Based Models[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2010, 32(9): 1627-1645.
- [10] Girshick R, Donahue J, Darrell T, et al. Rich Feature Hierarchies for Accurate Object Detection and Semantic Segmentation[C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2014: 580-587.
- [11] Girshick R. Fast R-CNN[C]. Proceedings of the IEEE International Conference on Computer Vision. 2015: 1440-1448.
- [12] Ren S, He K, Girshick R, et al. Faster R-CNN: Towards Real-Time Object Detection with Region Proposal Networks[C]. Advances in Neural Information Processing Systems. 2015, 28.
- [13] Liu W, Anguelov D, Erhan D, et al. SSD: Single Shot MultiBox Detector[C]. European conference on computer vision. Cham: Springer International Publishing, 2016: 21-37.
- [14] Lin T Y, Goyal P, Girshick R, et al. Focal Loss for Dense Object Detection[C]. Proceedings of the IEEE International Conference on Computer Vision. 2017: 2980-2988.
- [15] Redmon J, Divvala S, Girshick R, et al. You Only Look Once: Unified, Real-Time Object Detection[C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2016: 779-788.
- [16] Carion N, Massa F, Synnaeve G, et al. End-to-End Object Detection with Transformers[C]. European conference on computer vision. Cham: Springer International Publishing, 2020: 213-229.
- [17] Zhu X, Su W, Lu L, et al. Deformable DETR: Deformable Transformers for End-to-End Object Detection[J]. arXiv preprint arXiv:2010.04159, 2020.

- [18] Zhang H, Li F, Liu S, et al. DINO: DETR with Improved DeNoising Anchor Boxes for End-to-End Object Detection[J]. arXiv preprint arXiv:2203.03605, 2022.
- [19] Zhao Y, Lv W, Xu S, et al. DETRs Beat YOLOs on Real-time Object Detection[C]. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2024: 16965-16974.
- [20] Sommer L, Schumann A, Schuchert T, et al. Multi Feature Deconvolutional Faster R-CNN for Precise Vehicle Detection in Aerial Imagery[C]. 2018 IEEE Winter Conference on Applications of Computer Vision. 2018: 635-642.
- [21] Song J, Yu Z, Qi G, et al. UAV Image Small Object Detection Based on RSAD Algorithm[J]. Applied Sciences, 2023, 13(20): 11524.
- [22] Zhu X, Lyu S, Wang X, et al. TPH-YOLOv5: Improved YOLOv5 Based on Transformer Prediction Head for Object Detection on Drone-Captured Scenarios[C]. Proceedings of the IEEE/CVF International Conference on Computer Vision. 2021: 2778-2788.
- [23] Zhang Z. Drone-YOLO: An Efficient Neural Network Method for Target Detection in Drone Images[J]. Drones, 2023, 7(8): 526.
- [24] 何宇豪, 易明发, 周先存, 等. 基于改进的 YOLOv5 的无人机图像小目标检测[J]. 智能系统学报, 2023, 19(3): 635-645.
- [25] 何植仟, 曹立杰. UAVAI-YOLO: 无人机航拍图像的小目标检测模型[J]. Chinese Journal of Intelligent Science & Technology, 2024, 6(2).
- [26] Ni J, Zhu S, Tang G, et al. A Small-Object Detection Model Based on Improved YOLOv8s for UAV Image Scenarios[J]. Remote Sensing, 2024, 16(13): 2465.
- [27] Qi S, Song X, Shang T, et al. MSFE-YOLO: An Improved YOLOv8 Network for Object Detection on Drone View[J]. IEEE Geoscience and Remote Sensing Letters, 2024, 21: 1-5.
- [28] Chen W, Liu J, Liu T, et al. PCPE-YOLO with a Lightweight Dynamically Reconfigurable Backbone for Small Object Detection[J]. Scientific Reports, 2025, 15(1): 29988.
- [29] Wei X, Yin L, Zhang L, et al. DV-DETR: Improved UAV Aerial Small Target Detection Algorithm Based on RT-DETR[J]. Sensors, 2024, 24(22): 7376.
- [30] Rumelhart D E, Hinton G E, Williams R J. Learning representations by back-propagating errors[J]. Nature, 1986, 323(6088): 533-536.
- [31] Nair V, Hinton G E. Rectified Linear Units Improve Restricted Boltzmann Machines[C]. Proceedings of the 27th International Conference on Machine Learning. 2010: 807-814.
- [32] Maas A L, Hannun A Y, Ng A Y. Rectifier Nonlinearities Improve Neural Network Acoustic Models[C]. Proc. icml. 2013, 30(1): 3.
- [33] Elfving S, Uchibe E, Doya K. Sigmoid-weighted linear units for neural network function approximation in reinforcement learning[J]. Neural Networks, 2018, 107: 3-11.
- [34] Rahman M M, Marculescu R. MK-UNet: Multi-kernel Lightweight CNN for Medical Image Segmentation[C]. Proceedings of the IEEE/CVF International Conference on Computer Vision. 2025: 1053-1062.
- [35] Misra D, Nalamada T, Arasanipalai A U, et al. Rotate to Attend: Convolutional Triplet Attention Module[C]. Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision. 2021: 3139-3148.
- [36] Chen J, Kao S H, He H, et al. Run, Don't Walk: Chasing Higher FLOPS for Faster Neural Networks[C]. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2023: 12021-12031.
- [37] Zhang Y, Zhao C, Ni B, et al. Exploiting channel similarity for accelerating deep convolutional neural networks[J]. arXiv preprint arXiv:1908.02620, 2019.

- [38] Tang S, Zhang S, Fang Y. HIC-YOLOv5: Improved YOLOv5 for Small Object Detection[C]. 2024 IEEE International Conference on Robotics and Automation. 2024: 6614-6619.

致谢

论文写到这里，也到了该认真说一句感谢的时候。大学这几年里，我在学习和毕业设计过程中得到了很多人的帮助和关心，这些支持让我能够一步一步把论文完成下来。

首先要感谢我的导师刘洪波教授。无论是选题确定、实验推进，还是论文修改，刘老师都给予了我细致耐心的指导。老师严谨的治学态度、认真负责的工作作风，也让我明白了做研究不能只停留在表面，而是要把问题想清楚、做扎实。在论文写作过程中，每当我遇到思路不清或实验上的困难，刘老师都给了我很多启发和帮助。

同时，感谢大连海事大学信息科学技术学院的各位老师。大学期间，你们的教学让我逐步建立起计算机科学与技术专业的知识体系，也为我完成本次论文打下了基础。感谢身边的同学们，大家在平时学习、交流和相处中给了我很多帮助，也给我的大学生活留下了许多难忘的回忆。

最后，我最想感谢的是我的家人。你们一直以来的理解、包容和支持，是我能够安心学习、坚持走到现在的重要原因。每当我感到疲惫和迷茫时，家人给予我的鼓励，都是我继续向前的动力。

还要感谢大连海事大学为我提供了良好的学习环境和成长平台。大学时光即将结束，但这段经历对我的影响会一直延续下去。